Integrantes: Jordana Escalona · David Moreira · José Luis Martín · Alejandro Suarez

ANÁLISIS EXPLORATORIO DE DATOS (EDA) — SPRINT 2

Datos limpios e integrados

Este EDA retoma la exploración inicial del Sprint 1, ahora sobre los archivos limpios de la carpeta data/processed del repositorio. La limpieza y transformación se hizo con OpenRefine (Sysarmy, programas, CPCI), Pentaho (unión de los 9 programas en un solo CSV) y Python (pandas) para el empleo del CEP XXI y los controles; no se usó una base de datos MySQL. Los CSV resultantes se cargaron en el modelo de Power BI (EQ3_PP1_modelo.pbix). Las tablas y gráficos de este documento se calcularon con Python (pandas y matplotlib) sobre esos mismos CSV, en el notebook analysis/eda_sprint2.ipynb del repositorio (se puede ejecutar en Google Colab).

1. Preguntas que guían la exploración

Las preguntas se reformularon para alinearlas con los ejes del proyecto, según la devolución docente del Sprint 1 ("Revisar que estén alineadas con los ejes y respondan al objetivo del proyecto"). Juntas cuentan una historia en tres pasos.

Hilo conductor: ¿Dónde está el trabajo en datos e inteligencia artificial, cuánto vale, y los fondos públicos de la Economía del Conocimiento acompañan esa distribución?

P1 muestra cuánto vale el trabajo y dónde está → P2 muestra adónde va la plata pública → P3 compara si ambas cosas coinciden.

Preg.	Pregunta (reformulada)	Eje	Qué se explora
P1	¿Cuánto cobran los puestos de Datos e IA frente al resto de IT, y cómo cambia esa diferencia entre CABA y el resto del país?	Perfiles laborales + territorio	Salario bruto Full-Time por grupo y seniority; efecto de la composición; diferencia por zona (CABA, Buenos Aires, resto del país); contraste con el convenio AGC y con CPCI Córdoba.
P2	¿Qué provincias concentran los fondos de los programas de la Economía del Conocimiento y cuántos beneficios recibió cada una?	Distribución territorial de fondos públicos	Monto por habitante en pesos de 2023 (IPC y Censo 2022); monto típico por beneficio; concentración y diversidad de programas. Los totales se usan solo como contexto.
P3	¿Los fondos se distribuyen en proporción al empleo informático registrado de cada provincia?	Territorio + empleo registrado	Índice fondos / empleo (% de fondos ÷ % del empleo de la rama 62, 2020–2023) y fondos por puesto de trabajo informático. Comparación descriptiva, sin buscar causas.

2. Información de los datasets (después del ETL)

Se agregaron datasets complementarios que permiten pasar de valores absolutos a indicadores relativos (por habitante, en pesos constantes) y validar los salarios con otras fuentes.

Archivo (data/processed)	Fuente	Preg.	Registros	Variables	Uso
sysarmy_limpio.csv	Encuesta Sysarmy 2026.1	P1	4.939	15	Principal
programas_limpio.csv	datos.gob.ar – 9 programas EDC	P2, P3	1.035	8	Principal
empleo_provincia_limpio.csv	CEP XXI – puestos por provincia y CLAE2	P3	20.115	5	Principal
dim_provincia	Tabla de provincias (mapa_provincias)	Todas	24	3	Une las tablas
poblacion_provincia_2022	INDEC – Censo 2022	P2	24	—	Monto por habitante

Archivo (data/processed)	Fuente	Preg.	Registros	Variables	Uso
ipc_mensual / ipc_anual	INDEC – IPC	P2	—	—	Pesos de 2023
tipo_cambio_a3500_mensual	BCRA – Com. A 3500	P1	—	—	Contexto (sueldos en dólares)
grilla_agc_enero2026.csv	Convenio AGC (ene-2026, +20 %)	P1	3	3	Validación
cpci_honorarios_recomendados_2026_09.csv	CPCI Córdoba (09-2026)	P1	62	5	Validación

Los cambios principales respecto del Sprint 1: Sysarmy pasó de 60 a 15 variables (solo las que usa el análisis) y se agregó grupo_puesto; los programas tienen id_beneficio, cuit y provincia_id; el CEP XXI pasó de 3,59 millones de filas por departamento a 20.115 filas por provincia, año y rama (promedio anual de puestos).

3. Exploración estructural

3.1 Sysarmy limpio (4.939 registros, 15 variables)

Variable	Tipo	Valores posibles / rango	Estadísticos o frecuencias
salario_bruto	Numérica	$200.000 – $20.000.000	Mediana $3,27 M; media $3,88 M (asimétrica)
grupo_puesto	Categórica	Datos e IA / Resto IT	440 (8,9 %) / 4.499
seniority	Categórica	Junior / Semi-Senior / Senior	533 / 1.514 / 2.892
dedicacion	Categórica	Full-Time / Part-Time	4.724 / 215
provincia_id	Numérica (clave)	24 jurisdicciones	Une con dim_provincia
anios_experiencia	Numérica	0 – 48	Mediana 7
modalidad	Categórica	Remoto / Híbrido / Presencial	2.352 / 2.160 / 427
sueldo_dolarizado	Binaria (0/1)	0 = pesos; 1 = algún pago en dólares	1.583 respuestas (32 %)
uso_ia	Numérica	0 – 5	Media 3,85; 43 % responde 5
genero / edad	Categórica / Numérica	7 categorías / 16 – 75 años	Mujeres cis 19,9 %; edad mediana 36

Puestos del grupo Datos e IA: BI Analyst / Data Analyst (183), Data Engineer (144), Data Scientist (93), AI Engineer (12), Data Governance / GRC (6) y AI / Prompt / Chatbots (2). DBA (32) quedó en Resto IT.

3.2 Programas de la Economía del Conocimiento (1.035 registros, 8 variables)

Variable	Tipo	Valores posibles / rango	Estadísticos o frecuencias
programa	Categórica	9 programas	Capacitación 4.0 tiene 456 filas (44 %)
tipo_beneficiario	Categórica	Gobierno / Empresa / Polo-Clúster / Empresa-Institución	456 / 438 / 108 / 33
provincia_id	Numérica (clave)	24 jurisdicciones	Todas reciben fondos
anio	Numérica	2020 – 2023	218 / 549 / 220 / 48 beneficios
monto	Numérica	$22.500 – $50.000.000	Total $7.132,8 M; mediana $1,2 M
cuit / beneficiario	Texto / Numérica	—	Identifican al beneficiario

Programa	Benef.	Total ($ M)	Mediana ($ M)	Años	Provincias
NODOS	108	2.267,6	20,0	2021–2023	24
SOLUCIONA	169	1.711,0	11,4	2020–2021	16
SOLUCIONA II	63	1.107,7	19,9	2022	10
POTENCIAR Satelital	33	676,4	18,0	2021–2023	4

Programa	Benef.	Total ($ M)	Mediana ($ M)	Años	Provincias
Producción Colaborativa	61	406,7	7,0	2021–2022	8
POTENCIAR Videojuego	45	346,1	8,0	2022–2023	9
SOLUCIONA VERDE	19	312,3	18,6	2021	5
Capacitación 4.0	456	226,5	0,39	2020–2022	23
FORTALECER	81	78,4	1,07	2021	21
Total	1.035	7.132,8	1,2	2020–2023	24

Monto por año (pesos corrientes): 2020 $745,7 M; 2021 $2.847,8 M; 2022 $2.497,4 M; 2023 $1.041,8 M. Ajustado a pesos de 2023 con el IPC, el total pasa a $22.794 M (unas 3,2 veces el valor nominal).

3.3 CEP XXI – Empleo por provincia (20.115 registros, 5 variables)

Variable	Tipo	Valores posibles / rango	Estadísticos o frecuencias
provincia_id	Numérica (clave)	24 jurisdicciones	Une con dim_provincia
anio	Numérica	2014 – 2023	10 años
clae2	Numérica	85 ramas	Se usa la 62 (servicios informáticos)
puestos_promedio	Numérica	Promedio anual de puestos	Rama 62: 82.224 (2014) → 137.173 (2023)
meses_con_dato	Numérica	1 – 12	89 % de las filas tiene 12 meses

3.4 Datasets complementarios

Dataset	Para qué se usa	Observación
Población (Censo 2022)	Calcular monto por habitante (P2)	Total país 45.892.285 habitantes
IPC (INDEC)	Llevar los montos a pesos de 2023 (P2)	Cambia poco el ranking: top 3 = 58,5 % nominal y 59,6 % en pesos 2023
Tipo de cambio A3500 (BCRA)	Contexto de sueldos en dólares (P1)	Sin relación en el modelo; se usa como referencia
Convenio AGC (ene-2026)	Piso salarial por seniority (P1)	Junior $1,71 M; Semi-Senior $1,97 M; Senior $2,26 M
CPCI Córdoba (09-2026)	Contrastar salarios por perfil (P1)	62 perfiles; 55 sin seniority y ninguno Semi-Senior

4. Calidad de los datos después del ETL

Problemas del Sprint 1 y cómo se resolvieron

Problema detectado en el Sprint 1	Qué se hizo	Resultado
127 salarios leídos como texto por la coma decimal (Sysarmy)	Transformación en OpenRefine (quitar $ y puntos, coma → punto, a número)	salario_bruto 100 % numérico, 0 nulos
Nombres de provincia con espacios y mayúsculas distintas	Tabla mapa_provincias y clave provincia_id	24 jurisdicciones únicas en las 3 bases
Montos con formatos distintos según el programa	Normalización en OpenRefine y unión con Pentaho (unir_programas.ktr)	monto numérico en las 1.035 filas
Valores −99 del CEP XXI (secreto estadístico)	Reemplazo por vacío (no es un valor real)	525 vacíos, ninguno en la rama 62
9.996 filas del CEP XXI sin provincia	Excluidas al agrupar por provincia	Afecta ~0,3 % del empleo de la rama 62
Puestos de datos e IA sin agrupar	Columna grupo_puesto con criterio definido por el equipo	440 Datos e IA / 4.499 Resto IT
Período distinto entre fondos y empleo	Se compara 2020–2023 en ambas tablas	P3 con el mismo período

Controles realizados

- Cantidad de filas: Sysarmy 4.939, programas 1.035 y 24 provincias en dim_provincia, iguales a los originales.
- Sin nulos en los campos clave (provincia_id, salario_bruto, seniority, grupo_puesto, programa, anio, monto).
- Sin id repetidos en Sysarmy ni en programas.
- Totales de control: monto total $7.132.754.692,09 (coincide con Power BI) y empleo de la rama 62 por año igual al calculado en el Sprint 1.
- Salarios contrastados con tres fuentes: CEP XXI (oficial), convenio AGC (piso) y CPCI Córdoba (consejo profesional).

Puntos que siguen abiertos

- **Filas parecidas en Capacitación 4.0:** 11 filas repiten municipio, año y monto (por ejemplo Almirante Brown 2020, $250.000 dos veces). En el archivo original son proyectos distintos, por eso se conservaron y se distinguen con id_beneficio.
- **pagos_en_dolares** tiene 3.356 vacíos: son estructurales (quien cobra todo en pesos no responde esa pregunta). Para el análisis se usa sueldo_dolarizado (0/1).
- **genero** (1 vacío) y **edad** (3 vacíos): no afectan las preguntas.
- **CPCI** no distingue Semi-Senior y 55 de 62 perfiles no tienen seniority: sirve como referencia por perfil, no para comparar por nivel.
- **Programas hasta 2023:** el programa vigente (KIT 4.0) no tiene datos abiertos. Se pidió la información al Ministerio de Economía (Ley 27.275) el 23/10/2026; respuesta esperada el 13/11/2026.

5. Exploración mediante visualizaciones

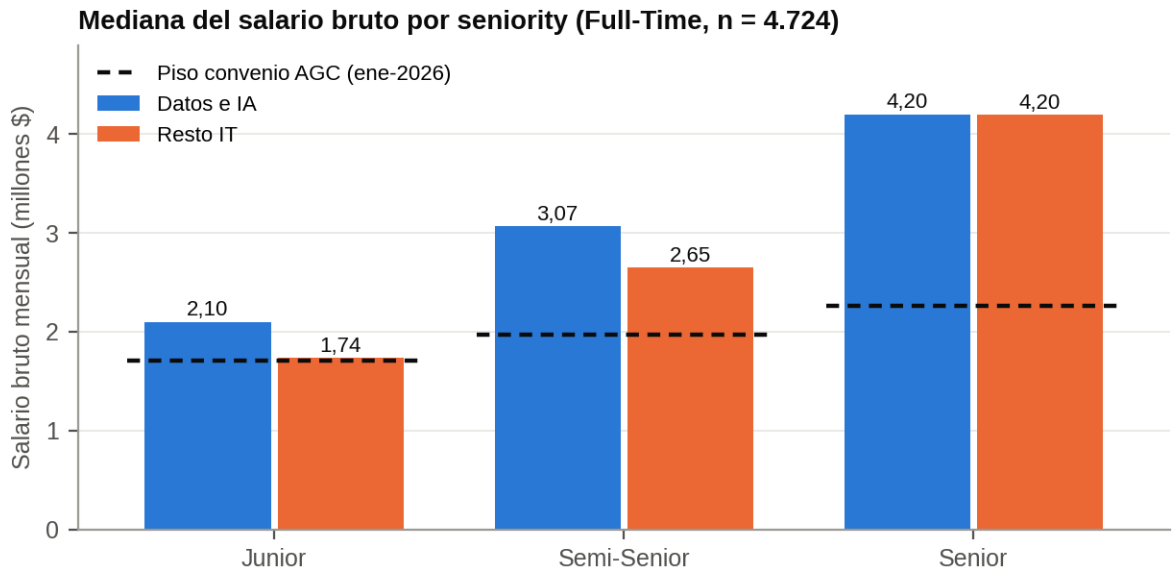


Gráfico 1. Pregunta 1: mediana del salario bruto por seniority y piso del convenio AGC.

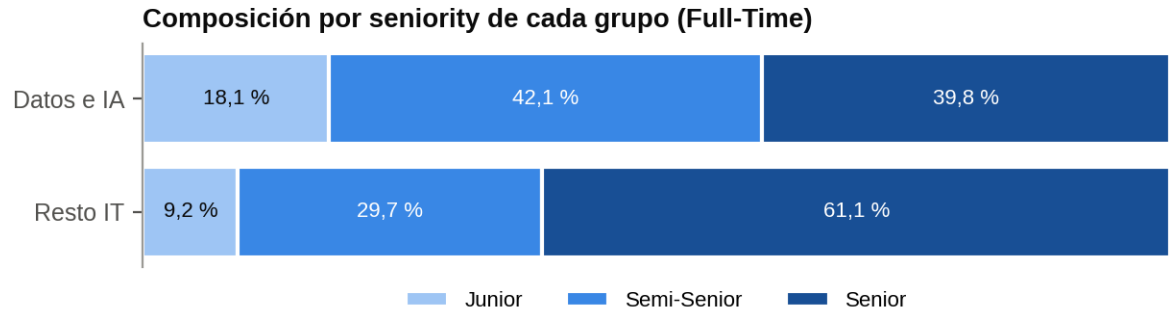


Gráfico 2. Pregunta 1: el grupo Datos e IA tiene menos personas Senior, lo que baja su mediana general.

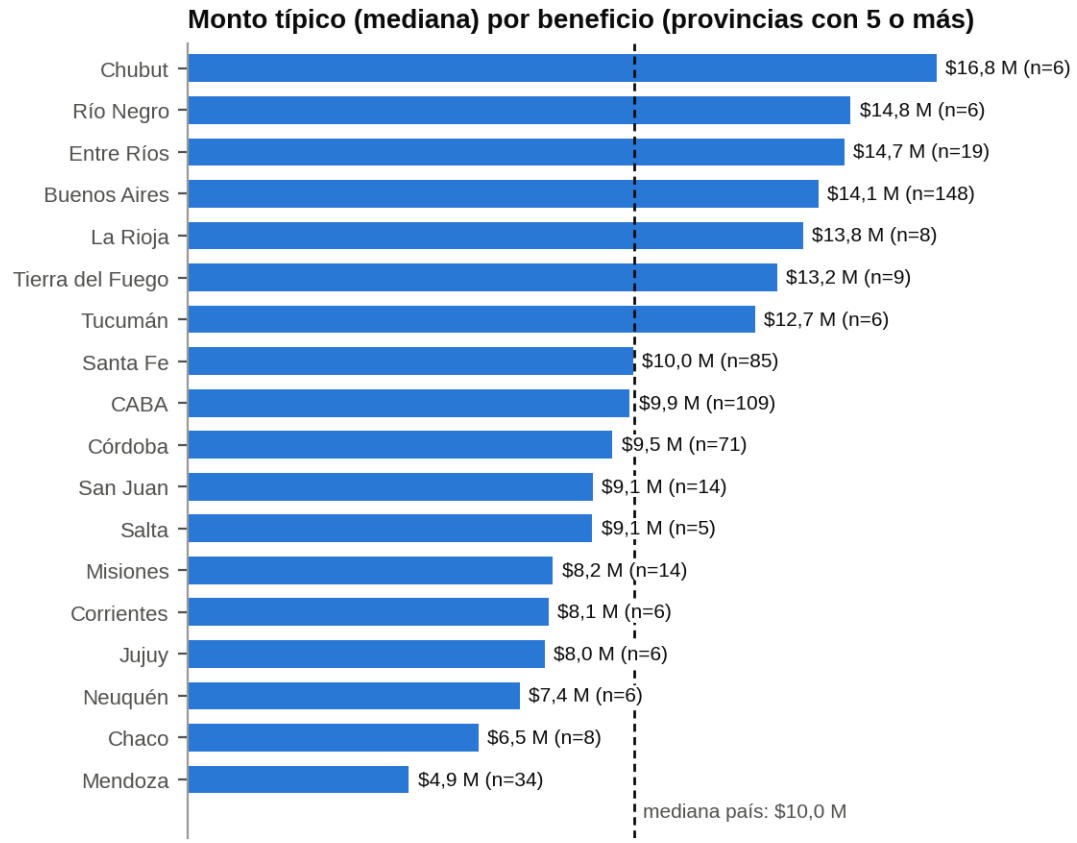


Gráfico 3. Pregunta 2: tamaño típico de cada beneficio. Sin Capacitación 4.0 (beneficios chicos a municipios) y solo provincias con 5 o más beneficios.

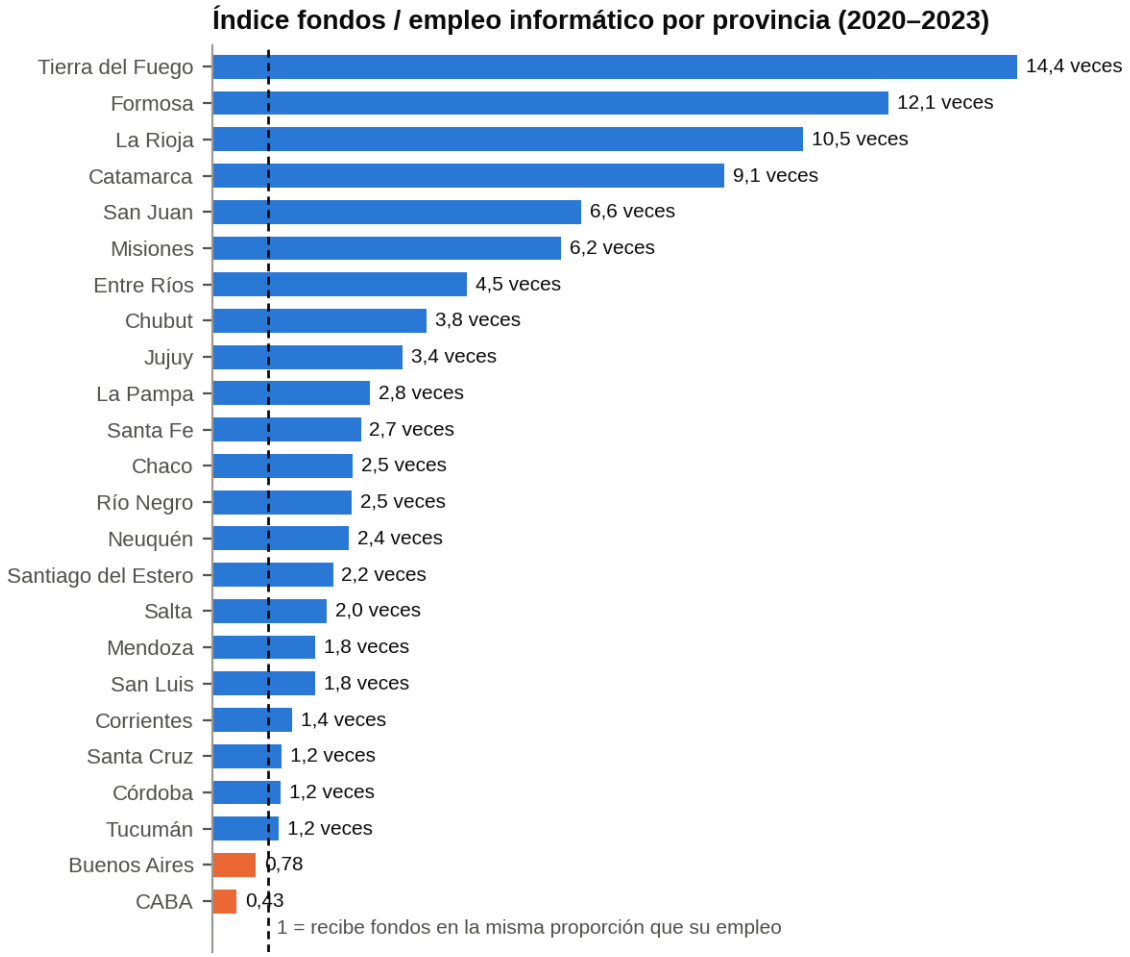


Gráfico 4. Pregunta 3: índice = % de los fondos ÷ % del empleo informático (sin Capacitación 4.0). Mayor que 1: recibe más fondos que su peso en el empleo; menor que 1: recibe menos.

6. Observaciones por pregunta

Siguen siendo descriptivas: muestran qué pasa en los datos, no por qué pasa. Siguiendo la devolución docente, se priorizan indicadores relativos (por seniority, por habitante, por puesto de trabajo, índices). Los totales absolutos reflejan sobre todo el tamaño de cada provincia y se dejan solo como contexto en la sección 3.

Pregunta 1 – Salarios

Seniority	n Datos e IA	n Resto IT	Mediana Datos e IA	Mediana Resto IT	Diferencia
Junior	77	397	$2,10 M	$1,74 M	+20,9 %
Semi-Senior	179	1.275	$3,07 M	$2,65 M	+15,8 %
Senior	169	2.627	$4,20 M	$4,20 M	≈ 0 %
Total	425	4.299	$3,10 M	$3,40 M	−8,8 %

- En el total, Datos e IA cobra 8,8 % menos; pero dentro de cada seniority cobra igual o más (+20,9 % Junior, +15,8 % Semi-Senior). La diferencia general se explica por la composición: el grupo tiene 39,8 % de Senior contra 61,1 % en Resto IT (efecto composición).

- Las tres medianas de Datos e IA superan el piso del convenio AGC. En Junior, la mediana de Resto IT ($1,74 M) queda casi en el piso ($1,71 M).
- Dentro del grupo hay mucha diferencia entre puestos: Data Scientist $4,18 M, Data Engineer $3,60 M, BI / Data Analyst $2,60 M.
- CPCI Córdoba confirma el orden de magnitud: Científico de Datos $4,91 M (Sysarmy Data Scientist $4,0 M); DBA $2,98 M (Sysarmy $2,95 M).

Diferencia por zona (conexión de P1 con el territorio). Ventaja de la mediana de Datos e IA sobre Resto IT, Full-Time (n = respuestas de Datos e IA):

Seniority	CABA	Buenos Aires	Resto del país
Junior	+20 % (n = 45)	0 % (n = 15)	+18 % (n = 17)
Semi-Senior	+10 % (n = 97)	+31 % (n = 27)	+19 % (n = 55)
Senior	−2 % (n = 94)	−4 % (n = 35)	+10 % (n = 40)

- La ventaja de Datos e IA no es solo de CABA: en el resto del país se mantiene en los tres niveles.
- El 55 % de las respuestas de Datos e IA son de CABA; fuera de CABA hay pocas (77 en Buenos Aires y 112 en el resto del país), así que los resultados por zona son orientativos.

Pregunta 2 – Fondos por provincia

- **Por habitante el mapa cambia.** En pesos de 2023, Tierra del Fuego recibió $2.326 por habitante, CABA $1.188 y La Rioja $1.000, frente a un promedio nacional de $497. Buenos Aires, la que más dinero recibió en total, queda por debajo del promedio ($399).
- **El tamaño de los beneficios no depende del tamaño de la provincia.** Sin Capacitación 4.0, el beneficio típico es de $10 M. Chubut ($16,8 M), Río Negro ($14,8 M) y Entre Ríos ($14,7 M) tienen beneficios más grandes que CABA ($9,9 M) o Córdoba ($9,5 M); Mendoza está en $4,9 M. Las provincias chicas reciben pocos beneficios, pero de monto alto.
- **Pocos beneficios grandes explican mucho dinero:** el 10 % de los beneficios de mayor monto concentra el 41 % del total. NODOS (polos y clústeres) es el programa que más distribuyó.
- **Diversidad de programas:** Buenos Aires recibió de los 9 programas; Formosa, Corrientes, San Luis, La Pampa, Santiago del Estero y Santa Cruz, de solo 3.
- Ajustar por inflación casi no cambia la concentración (58,5 % nominal y 59,6 % en pesos de 2023 para las tres primeras), así que el resultado no depende del año en que se otorgó cada beneficio.

Pregunta 3 – Fondos y empleo

Para no comparar tamaños, se calculó un **índice fondos / empleo**: el % de los fondos de cada provincia dividido por su % del empleo informático (2020–2023, sin Capacitación 4.0). Si vale 1, la provincia recibe fondos en la misma proporción que su empleo.

Provincia	% fondos	% empleo	Índice	Fondos por puesto informático (por año)
Tierra del Fuego	2,0 %	0,1 %	14,4	$789.051
Formosa	1,0 %	0,1 %	12,1	$663.026
La Rioja	2,0 %	0,2 %	10,5	$578.779
Catamarca	0,9 %	0,1 %	9,1	$501.609
Promedio país	—	—	1,0	$54.864
Buenos Aires	29,7 %	38,2 %	0,78	$42.622
CABA	16,5 %	38,4 %	0,43	$23.639

- **22 de las 24 provincias tienen índice mayor que 1:** reciben más fondos que su peso en el empleo informático. Solo Buenos Aires (0,78) y CABA (0,43) quedan por debajo.
- Las provincias con poco empleo informático registrado (Tierra del Fuego, Formosa, La Rioja, Catamarca) reciben entre 9 y 14 veces lo que les correspondería por su empleo. Por cada puesto informático, Tierra del Fuego recibió $789.051 por año y CABA $23.639: 33 veces menos.

- Esto sugiere que los programas no se repartieron en proporción al empleo existente sino con un criterio más federal. No se buscan causas: es una lectura descriptiva para validar con las bases de cada programa.
- Lectura con cuidado: en provincias con muy poco empleo, un solo beneficio grande mueve mucho el índice (Formosa tiene 4 beneficios fuera de Capacitación 4.0).

7. Respuestas a las líneas abiertas en el Sprint 1

Pregunta del Sprint 1	Estado	Lo que encontramos
¿La diferencia salarial se mantiene dentro de cada seniority?	Respondida	No: se invierte. Datos e IA cobra más en Junior y Semi-Senior e igual en Senior.
¿Y entre puestos del grupo?	Respondida	Data Scientist $4,18 M > Data Engineer $3,60 M > BI / Data Analyst $2,60 M.
¿Salarios en pesos vs en dólares?	Respondida	Con algún pago en dólares, Datos e IA: $4,20 M vs $2,95 M en pesos (Resto IT: $4,50 M vs $3,00 M).
¿Uso de herramientas de IA según puesto y seniority?	Parcial	Datos e IA usa algo más IA (4,0 vs 3,8 sobre 5); casi no cambia por seniority (3,8 – 3,9).
¿La mayor participación de mujeres en Datos e IA se mantiene en cada seniority?	Respondida	Sí: Junior 30 % vs 29 %, Semi-Senior 28 % vs 23 %, Senior 24 % vs 16 %.
¿Cambia el ranking con IPC o por habitante?	Respondida	Con IPC casi no cambia; por habitante, sí (Tierra del Fuego, CABA y La Rioja arriba).
¿Qué sectores recibieron más fondos?	Pendiente	La variable sector_edc no se unificó entre programas.
¿Cuánto concentran los beneficios más grandes?	Respondida	El 10 % de mayor monto concentra el 41 % del dinero; NODOS distribuyó más.
¿Qué provincias tienen rankings muy distintos?	Respondida	Se respondió con el índice fondos / empleo: Tierra del Fuego 14,4, Formosa 12,1, La Rioja 10,5; CABA 0,43.
¿Qué provincias dependieron de pocos programas?	Respondida	Seis provincias recibieron de solo 3 programas; Buenos Aires, de los 9.
¿Y con todas las ramas EDC (CLAE 59, 63, 72)?	Pendiente	Se dejó la rama 62 para mantener el foco en servicios informáticos.
¿Cómo evolucionó el empleo en provincias con más fondos que empleo?	Parcial	Entre 2020 y 2023 creció más en Entre Ríos (+60 %), Tierra del Fuego (+99 %) y La Rioja (+195 %) que en el país (+24 %), pero parten de bases muy chicas. No se atribuyen causas.
¿KIT 4.0 tendrá una distribución similar?	En curso	Solicitud de acceso a la información enviada el 23/10/2026.

8. Nuevas líneas de exploración (Sprint 3)

- Sumar al tablero de Power BI la comparación de la Pregunta 1 por zona (hoy está calculada en Python).
- Calcular la Pregunta 1 con salarios en dólares (tipo de cambio A3500) para comparar con referencias internacionales.
- Medir la brecha de género dentro de Datos e IA por seniority, no solo la participación.
- Cruzar el índice fondos / empleo con el monto por habitante para ver si las mismas provincias aparecen arriba en los dos.
- Unificar sector_edc para responder qué sectores recibieron más fondos.
- Si llegan los datos de KIT 4.0, sumarlos con el mismo esquema (provincia_id, anio, monto) y comparar con los programas 2020–2023.